

マーケティングサイエンス

期末レポート

ソーシャル・データサイエンス学部 3 年

5123017x 桑原 周平

【問題1 ハザードモデル】

1 分析の準備

1.1 データの読み込み

まず、デスクトップのフォルダ内の `chapter_09_churn_data.csv` を R の作業ディレクトリにコピーし、`data_chap09_churn` として保存。念の為ワークスペースはクリアし、データが問題なく表示できることを確認。

ソースコード 1 データの読み込み

```
1 file.copy(  
2   from = "~/Desktop/マーケティングサイエンス/chapter_09_churn_data.csv",  
3   to   = file.path(getwd(), "chapter_09_churn_data.csv")  
4 )  
5 rm(list = ls())  
6  
7 data_chap09_churn <- read.csv("chapter_09_churn_data.csv", header = TRUE)  
8 head(data_chap09_churn)
```

1.2 パッケージのインストール

ソースコード 2 データの読み込み

```
1 install.packages(c("survival", "flexsurv", "survminer",  
2                   "dplyr", "stargazer", "broom", "readr"))  
3  
4 library(survival)  
5 library(flexsurv)  
6 library(survminer)  
7 library(dplyr)  
8 library(stargazer)  
9 library(broom)  
10 library(readr)
```

2 DM 有無の比例ハザードモデル

2.1 基礎分析

比例ハザードモデルを用いて DM 有無による離脱期間の違いを推定する前に、基本的な分析を行う。

ソースコード 3 基礎分析

```
1 nrow(subset(data_chap09_churn, Event == 0))
2 summary(data_chap09_churn[data_chap09_churn$Event == 1,]$Duration)
3
4 hist(data_chap09_churn$Duration, main = '',
5       xlab = "Duration", ylab = "Number of Customers")
6
7 dur_DM <- data_chap09_churn[data_chap09_churn$DM == 1,2]
8 dur_no_DM <- data_chap09_churn[data_chap09_churn$DM == 0,2]
9
10 boxplot(dur_DM, dur_no_DM,
11         names = c("DM", "No-DM"), ylab = "Duration")
```

1 行目により、最後まで解約しなかった顧客数は 23 人と分かり、2 行目以降により以下の結果が得られた。

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
3.00	23.00	31.00	30.79	39.00	54.00

表 1 解約までの期間の記述統計




図 1 解約期間の分布




図2 DM有無による解約期間の違い

以上の結果から、全体として1000人中977人が観測期間内に解約しており、最も早い解約は3日目、最も遅い解約は54日目に発生していることが分かった。中央値は31日であり、多くの顧客がこの付近で解約している傾向が見られる。さらに、DMの受信有無によって顧客を2つのグループに分け、図2に示すように箱ひげ図を作成した結果、DMを受け取ったグループの方が、中央値および四分位数がやや高く、解約までの期間が長い傾向が見られた。これは、DMの受信が顧客の解約抑制に一定の効果を持つ可能性を示唆している。

2.2 比例ハザードモデルの実行

ソースコード4 比例ハザードモデルの実行

```

1 fit_DM <- flexsurvreg(
2   Surv(Duration, Event) ~ DM,
3   data = data_chap09_churn,
4   dist = "weibullPH"
5 )
6 coef_tbl_DM <- as.data.frame(fit_DM$res) %>%
7   tibble::rownames_to_column("variable") %>%
8   filter(variable %in% names(coef(fit_DM)))
9 coef_tbl_DM <- coef_tbl_DM %>%
10  mutate(
11    HR = exp(est),
12    HR_se = HR*se,
13    HR_L95 = exp(est - 1.96 * se),
14    HR_U95 = exp(est + 1.96 * se)
15  ) %>%
16  select(variable, coef = est, se.coef=se, HR, HR_se, HR_L95, HR_U95)

```

```

17 print(coef_tbl_DM, digits = 3)
18
19 plot(fit_DM, type = "hazard", ci = TRUE,
20      newdata = data.frame(DM = 1),
21      col = "blue", lwd = 2,
22      xlab = "Duration", ylab = "Hazard",
23      main = "")
24 plot(fit_DM, type = "hazard", ci = TRUE,
25      newdata = data.frame(DM = 0),
26      col = "red", lwd = 2, add = TRUE)
27 legend("topright", legend = c("DM", "no-DM"),
28      col = c("blue", "red"), lwd = 2)
29
30 plot(fit_DM, type = "survival", ci = TRUE,
31      newdata = data.frame(DM = 1), col = "blue")
32 plot(fit_DM, type = "survival", ci = TRUE,
33      newdata = data.frame(DM = 0), col = "red", add = TRUE)
34 legend("bottomleft", c("DM", "No-DM"), lwd = 1, col = c("blue", "red"))

```

DM の受信有無のみを説明変数とし、Weibull 分布に基づく比例ハザードモデルを推定した。その後、DM の有無によってハザード関数および生存関数を描画した結果、両者の間に差異が確認された。

表 2 DM の受信有無によるハザード比の推定結果

変数	HR	95% 信頼区間	回帰係数 (logHR)	標準誤差
DM	0.821	0.724 – 0.931	-0.197	0.064

表 2 より、DM 受信者のハザード比 (HR) は 0.821 (95% 信頼区間: 0.724–0.931) であり、1 を下回っていた。これは、DM を受信した顧客は、受信していない顧客と比べて離脱リスクが任意の時点において約 18% 低いことを意味する。また、信頼区間が 1 を含んでおらず、統計的に有意な効果が認められる。




図3 DM有無によるハザード関数

図3は、DM受信の有無によって推定されたハザード関数の違いを示している。任意の時点におけるハザードは、DMを受信した顧客（青線）の方が、受信していない顧客（赤線）よりも一貫して低く推移している。特に観察期間の後半（30日以降）にかけて、両者の差は徐々に拡大しており、DM受信が離脱リスクを抑制する効果を持つことが示唆される。また、95%信頼区間（点線）においても、2つのハザード関数は明確に分離しており、統計的にも意味のある差異が見られる。




図4 DM有無による生存関数

図4は、DM受信の有無による生存関数の違いを示している。青線（DM受信者）の生存率は、赤線（非受信者）と比較して常に高く、DMを受信した顧客の方がより長くサービスを継続している傾向が読み取れる。特に30～40日を境に顕著な差が生じており、DMの受信が顧客の離脱抑制に貢献している可能性が示されている。こちらも95%信頼区間は大きく重なっておらず、視覚的にも有意な違いが認められる。

3 デモグラフィック・行動特性 PHM

以下のコードでは、顧客のデモグラフィック属性（Sex, Age）および行動特性（Freq, Amount）を説明変数として、Weibull分布に基づく比例ハザードモデルを推定した。モデル推定後、特に有意なハザード比を示

した変数について、その水準の違いが生存関数およびハザード関数に与える影響を可視化した。

ソースコード 5 比例ハザードモデルの実行

```
1 fit_full <- flexsurvreg(  
2   Surv(Duration, Event) ~ Sex + Age + Freq + Amount,  
3   data = data_chap09_churn,  
4   dist = "weibullPH"  
5 )  
6  
7 coef_tbl_full <- as.data.frame(fit_full$res) %>%  
8   tibble::rownames_to_column("variable") %>%  
9   filter(variable %in% names(coef(fit_full)))  
10 coef_tbl_full <- coef_tbl_full %>%  
11   mutate(  
12     HR = exp(est),  
13     HR_se = HR*se,  
14     HR_L95 = exp(est - 1.96 * se),  
15     HR_U95 = exp(est + 1.96 * se)  
16   ) %>%  
17   select(variable, coef = est, se.coef=se, HR, HR_se, HR_L95, HR_U95)  
18 print(coef_tbl_full, digits = 3)  
19  
20 plot(fit_full, type = "survival", ci = TRUE,  
21   newdata = data.frame(Sex = mean(data_chap09_churn$Sex),  
22     Age = 20,  
23     Freq = mean(data_chap09_churn$Freq),  
24     Amount = mean(data_chap09_churn$Amount)),  
25   col = "blue", lwd = 2,  
26   xlab = "Duration", ylab = "Survival Probability",  
27   main = "Survival Function (age)")  
28 plot(fit_full, type = "survival", ci = TRUE,  
29   newdata = data.frame(Sex = mean(data_chap09_churn$Sex),  
30     Age = 40,  
31     Freq = mean(data_chap09_churn$Freq),  
32     Amount = mean(data_chap09_churn$Amount)),  
33   col = "red", lwd = 2, add = TRUE)  
34 legend("bottomleft", legend = c("age:20", "age:40"),  
35   col = c("blue", "red"), lwd = 2)  
36  
37 plot(fit_full, type = "hazard", ci = TRUE,
```

```

38     newdata = data.frame(Sex = mean(data_chap09_churn$Sex),
39                           Age = 20,
40                           Freq = mean(data_chap09_churn$Freq),
41                           Amount = mean(data_chap09_churn$Amount)),
42     col = "blue", lwd = 2,
43     xlab = "Duration", ylab = "Hazard",
44     main = "Hazard-Function-(age)")
45 plot(fit_full, type = "hazard", ci = TRUE,
46     newdata = data.frame(Sex = mean(data_chap09_churn$Sex),
47                           Age = 40,
48                           Freq = mean(data_chap09_churn$Freq),
49                           Amount = mean(data_chap09_churn$Amount)),
50     col = "red", lwd = 2, add = TRUE)
51 legend("bottomright", legend = c("age:20", "age:40"),
52     col = c("blue", "red"), lwd = 2)
53
54 colors <- c("red", "orange", "green", "blue", "purple") # 任意の色5
55 labels <- paste("Freq=", 1:5)
56 plot(fit_full, type = "hazard", ci = FALSE,
57     newdata = data.frame(Sex = mean(data_chap09_churn$Sex),
58                           Age = mean(data_chap09_churn$Age),
59                           Freq = 1,
60                           Amount = mean(data_chap09_churn$Amount)),
61     col = colors[1], lwd = 2,
62     xlab = "Duration", ylab = "Hazard",
63     main = "Hazard-Function-(Freq)")
64 for (i in 2:5) {
65     plot(fit_full, type = "hazard", ci = FALSE,
66     newdata = data.frame(Sex = mean(data_chap09_churn$Sex),
67                           Age = mean(data_chap09_churn$Age),
68                           Freq = i,
69                           Amount = mean(data_chap09_churn$Amount)),
70     col = colors[i], lwd = 2, add = TRUE)
71 }
72 legend("bottomright", legend = labels, col = colors, lwd = 2)
73
74 plot(fit_full, type = "survival", ci = FALSE,
75     newdata = data.frame(Sex = mean(data_chap09_churn$Sex),
76                           Age = mean(data_chap09_churn$Age),
77                           Freq = 1,

```



```

78         Amount = mean(data_chap09_churn$Amount)),
79     col = colors[1], lwd = 2,
80     xlab = "Duration", ylab = "Survival-Probability",
81     main = "Survival-Function-(Freq)")
82 for (i in 2:5) {
83     plot(fit_full, type = "survival", ci = FALSE,
84         newdata = data.frame(Sex = mean(data_chap09_churn$Sex),
85                             Age = mean(data_chap09_churn$Age),
86                             Freq = i,
87                             Amount = mean(data_chap09_churn$Amount)),
88         col = colors[i], lwd = 2, add = TRUE)
89 }
90 legend("bottomleft", legend = labels, col = colors, lwd = 2)

```

表 3 各説明変数におけるハザード比と 95% 信頼区間

変数	HR	95% 信頼区間	回帰係数 (logHR)	標準誤差
Sex	0.951	0.833 – 1.085	-0.050	0.067
Age	0.976	0.972 – 0.980	-0.025	0.002
Freq	0.857	0.814 – 0.903	-0.154	0.026
Amount	0.917	0.733 – 1.147	-0.087	0.114

表 3 に示す通り、年齢 (Age) および購買頻度 (Freq) は、離脱リスクに対して統計的に有意な影響を与えていた。具体的には、年齢のハザード比 (HR) は 0.976 (95%CI: 0.972–0.980) であり、年齢が 1 歳上がるごとに離脱リスクが約 2.4% 低下することを意味する。購買頻度 (Freq) の HR は 0.857 (95%CI: 0.814–0.903) で、頻度が 1 回増加するごとに離脱リスクが約 14.3% 低下する傾向が確認された。これらはともに信頼区間に 1 を含まず、有意であると判断される。一方で、性別 (Sex) の HR は 0.951 (95%CI: 0.833–1.085)、購買金額 (Amount) の HR は 0.917 (95%CI: 0.733–1.147) と推定されたが、いずれも信頼区間に 1 を含んでおり統計的に有意な差は認められなかった。したがって、これらの変数は本モデルにおいては離脱に対する影響は限定的であると解釈される。




図5 年齢別によるハザード関数/生存関数

図5は、年齢20歳(若年層)および40歳(中年層)の顧客におけるハザード関数および生存関数を一体として可視化したものである。青線(20歳)と赤線(40歳)を比較すると、若年層の方が任意の時点における離脱リスクが一貫して高く、生存率が低い傾向が見られる。特に観察期間後半にかけて両者の差は拡大しており、年齢が上がるほど顧客の離脱傾向が緩やかになることが視覚的にも確認された(他の年齢による描画でも確認済)。この結果は、ハザード比($HR = 0.976$, 95%CI: 0.972–0.980)という推定値と整合的であり、年齢の上昇が離脱リスクを有意に抑制する要因であることを裏づけている。




図6 利用頻度別によるハザード関数/生存関数

図6は、利用頻度が1～5の顧客に対するハザード関数と生存関数を可視化したものである。生存関数の比較から、利用頻度が高い顧客ほど、生存率が高く、サービスを長期的に継続している傾向が示された。またハザード関数においても、Freqが高いグループほど任意の時点における離脱ハザードが低く、離脱リスクの抑制効果が現れていることが読み取れる。この傾向は、利用頻度のハザード比の結果(表3)とも一致しており、利用頻度が顧客のロイヤリティを反映し、離脱リスク抑制の要因となっていると解釈できる。

【問題 2 因子分析】

1 分析の準備

1.1 データの読み込み

まず、デスクトップのフォルダ内の chapter_11.csv を R の作業ディレクトリにコピーし、data_chap11 として保存。念の為ワークスペースはクリアし、データが問題なく表示できることを確認。

ソースコード 6 データの読み込み

```
1 file.copy(  
2   from = "~/Desktop/マーケティングサイエンス/chapter_11.csv",  
3   to   = file.path(getwd(), "chapter_11.csv")  
4 )  
5 rm(list = ls())  
6 data_chap11 <- read.csv("chapter_11.csv", header = TRUE)  
7  
8 head(data_chap11)
```

1.2 パッケージのインストール

ソースコード 7 ライブラリの用意

```
1 install.packages(c("lavaan", "lavaanPlot", "psych", "dplyr", "semTools"))  
2  
3 library(lavaan)  
4 library(lavaanPlot)  
5 library(psych)  
6 library(dplyr)  
7 library(semTools)
```

1.3 信頼性・妥当性指標の算出方法

後にクロンバックの α 、CR、AVE が計算できるよう、事前に定義しておく。

ソースコード 8 信頼性・妥当性指標の算出方法

```
1 alpha.coef <- function(x){  
2   z <- (ncol(x) / (ncol(x) - 1)) *  
3     (1 - sum(diag(var(x))) / var(rowSums(x)))  
4   return(z)  
5 }
```

```

6
7 cr_ave <- function(Flab, StdEst){
8   FL <- StdEst[(StdEst["lhs"] == Flab) & (StdEst["op"] == "=~"), 3]
9   FLlist <- colSums(apply(StdEst["rhs"], 1,
10                          function(x, fl){x==fl}, FL)) > 0
11   Lm <- StdEst[FLlist & (StdEst["op"] == "=~"), 4]
12   e <- StdEst[FLlist & (StdEst["op"] == "~~"), 4]
13   CR <- sum(Lm)^2 / (sum(Lm)^2 + sum(e))
14   AVE <- sum(Lm^2) / (sum(Lm^2) + sum(e))
15   return(c(CR, AVE))
16 }

```

2 1 因子仮定の確認的因子分析

2.1 1 因子 CFA の実行

ソースコード 9 1 因子 CFA の実行

```

1 dat_lu <- data_chap11[, 10:17]
2
3 model_cfa_1F <- '
4   ~~LU=~LUAT1+LUAT2+LUAT3+
5   ~~~~~LUBE1+LUBE2+LUBE3+LUBE4+LUBE5
6   '
7 result_cfa_1F <- lavaan::sem(model_cfa_1F, data = dat_lu)
8 fitMeasures(result_cfa_1F)
9 summary(result_cfa_1F, standardized = TRUE)
10 fit_1F <- cfa(model_cfa_1F, data = dat_lu)
11 lavaanPlot(model = fit_1F,
12            edge_options = list(color = "grey20"),
13            coefs = T, covs = T, stand = TRUE)
14
15 alpha.coef(dat_lu)
16 standardizedSolution(result_cfa_1F)
17 std_est_1F <- standardizedSolution(result_cfa_1F)
18 cr_ave("LU", std_est_1F)

```

変数 LUAT1 から LUBE5 の合計 8 項目に対して、これらが単一の潜在因子 LU によって説明されるとい
う仮定のもと、確認的因子分析を実施した。data_chap11 のうち対象となる 8 項目（10 列目～17 列目）を抽
出して構成した dat_lu を用いて、lavaan パッケージの sem 関数により推定を実行。その後、fitMeasures で
モデルの適合度の出力、summary で詳細なパラメータを出力し、結果の可視化、信頼性・収束妥当性の検討

まで行った。

表 4 モデル適合度指標 (1 因子モデル)

指標	値	判断基準
GFI	0.734	≥ 0.90
AGFI	0.521	≥ 0.85
RMSEA	0.243	≤ 0.10
SRMR	0.130	≤ 0.08

表 2 に示すモデル適合度指標を見ると、GFI = 0.734、AGFI = 0.521 といういずれも基準 (各 0.90、0.85) を下回っており、モデル全体の適合度は十分とは言えない。また、RMSEA = 0.243、SRMR = 0.130 といった誤差指標も、それぞれ基準を満たしていない。以上より、この 1 因子モデルはデータに対して良好な適合度を示しているとは言えず、モデルの再検討が必要である可能性がある。

表 5 潜在因子 LU に対する各指標の因子負荷量と有意性

項目	Std.all	z 値	P 値
LUAT1	0.538	—	—
LUAT2	0.528	7.62	< .001
LUAT3	0.562	7.96	< .001
LUBE1	0.881	10.27	< .001
LUBE2	0.894	10.33	< .001
LUBE3	0.745	9.47	< .001
LUBE4	0.451	6.78	< .001
LUBE5	0.596	8.28	< .001

表 5 に示す通り、因子 LU は LUBE1 の 0.881 や LUBE2 の 0.894 をはじめとして一部の観測変数と高い関連を示す一方、LUBE4 の 0.451 や LUAT2 の 0.528 など、一部の観測変数に関しては関連が弱い可能性が示唆される。また、LUAT 系列 3 項目はいずれも 0.5 前後と中程度の因子負荷量であり、測定の妥当性について慎重な解釈が求められる。全体として、項目の一部において因子構造への貢献度に差があることが分かる。表 4

表 6 LU の信頼性および妥当性指標 (1 因子モデル)

指標	値	判断基準
クロンバック α	0.869	≥ 0.70
CR	0.859	≥ 0.70
AVE	0.447	≥ 0.50

に示すように、クロンバックの α 係数は 0.869 であり、一般的に信頼性の目安とされる 0.70 を大きく上回っていることから、項目間の一貫性は十分に高いと判断される。また、構成概念信頼性 (CR) は 0.859 と、こちらも基準値である 0.70 を上回っており、観測変数が共通の潜在因子によって安定的に説明されていることを示している。一方で、平均分散抽出量 (AVE) は 0.447 とわずかに基準値の 0.50 を下回っており、収束的

妥当性に懸念が残る結果となった。特に因子負荷量が高い LUBE4 の影響が、AVE の低下に寄与している可能性がある。




図 7 潜在因子 LU による 1 因子 CFA モデルの構造図

図 7 は、LU を潜在因子とする 1 因子 CFA モデルの構造図であり、LUAT および LUBE 系列の 8 項目がいずれも LU からの因子負荷によって説明される構造となっている。各矢印上の数値は完全標準化因子負荷量 (Std.all) を表しており、LUBE1 や LUBE2 等の負荷量が高い一方、LUBE4 の負荷量は相対的に低いことが視覚的にも確認できる。

2.2 2 因子 CFA の実行

比較のため、全く同様に二因子を仮定した確認的因子分析を実行。

ソースコード 10 1 因子 CFA の実行

```

1 model_cfa_2F <- '
2   ~AT =~ LUAT1 + LUAT2 + LUAT3
3   ~BE =~ LUBE1 + LUBE2 + LUBE3 + LUBE4 + LUBE5
4   '
5 result_cfa_2F <- lavaan::sem(model_cfa_2F, data = dat_lu)
6 fitMeasures(result_cfa_2F)
7 summary(result_cfa_2F, standardized = TRUE)
8 fit_2F <- cfa(model_cfa_2F, data = dat_lu)
9 lavaanPlot(model = fit_2F,
10            edge_options = list(color = "grey20"),
11            coefs = T, covs = T, stand = TRUE)
12
13 alpha.coef(dat_lu[, 1:3])
14 alpha.coef(dat_lu[, 4:8])
15 standardizedSolution(result_cfa_2F)
16 std_est_2F <- standardizedSolution(result_cfa_2F)
17 cr_ave("AT", std_est_2F)
18 cr_ave("BE", std_est_2F)

```

表 7 モデル適合度指標 (2 因子モデル)

指標	値	判断基準
GFI	0.931	≥ 0.90
AGFI	0.869	≥ 0.85
RMSEA	0.114	≤ 0.1
SRMR	0.066	≤ 0.08

表 7 に示す 2 因子モデルの適合度指標は、 $GFI = 0.931 (\geq 0.90)$ 、 $AGFI = 0.869 (\geq 0.85)$ 、 $SRMR = 0.066 (\leq 0.08)$ と基準を満たしており、モデル全体の適合度は良好であると判断できる。一方、 $RMSEA = 0.114$ は基準 (≤ 0.1) を上回っており、注意が必要であるが、他の指標が概ね良好であることから、1 因子モデルに比べて本モデルの方が適合度は高いと評価できる。

表 8 AT と BE に対する各指標の因子負荷量と有意性 (2 因子モデル)

因子	項目	Std.all	z 値	P 値
AT	LUAT1	0.802	—	—
AT	LUAT2	0.847	15.670	$< .001$
AT	LUAT3	0.828	15.415	$< .001$
BE	LUBE1	0.897	—	—
BE	LUBE2	0.910	22.562	$< .001$
BE	LUBE3	0.755	16.729	$< .001$
BE	LUBE4	0.451	8.382	$< .001$
BE	LUBE5	0.570	11.148	$< .001$

表 8 に示すように、因子 AT は LUAT1～LUAT3 の 3 項目すべてに対して高い因子負荷量 (0.80～0.85 程度) を示しており、十分な関連性が確認された。BE 因子に関しても LUBE1～LUBE3 は高い因子負荷量を示しているが、LUBE4 は 0.451 とやや低く、1 因子モデルと同様に妥当性の面で慎重な評価が必要である。一方、LUBE2 や LUBE1 は極めて高い因子負荷量 (0.910, 0.897) を示しており、BE 因子の中核をなす観測変数であると解釈できる。

表 9 AT と BE の信頼性および妥当性指標 (2 因子モデル)

因子	指標	値	判断基準
AT	クロンバック α	0.864	≥ 0.70
AT	CR	0.865	≥ 0.70
AT	AVE	0.682	≥ 0.50
BE	クロンバック α	0.849	≥ 0.70
BE	CR	0.850	≥ 0.70
BE	AVE	0.546	≥ 0.50

表 9 に示すように、潜在因子 AT および BE のいずれにおいても、クロンバック α 係数および CR はそれぞれ 0.85 前後と高く、いずれも基準値 (≥ 0.70) を十分に満たしている。これにより、各因子に含まれる観測変数群が高い一貫性を持ち、安定的に同一の概念を測定していることが示された。また、収束的妥当性を示す AVE は、AT が 0.682、BE が 0.546 となっており、いずれも基準とされる 0.50 を上回っている。特に AT は 0.682 と非常に高い値を示しており、観測変数が潜在因子を強く反映していることを意味する。また、BE の AVE も 0.546 と基準を満たしており、収束的妥当性が保たれていると解釈できる。

以上の結果から、2 因子モデルにおける AT および BE はともに信頼性・妥当性の両面において十分な水準を満たしていると評価できる。




図 8 2 因子 CFA モデルの構造図

図 8 は、LUAT および LUBE 系列の 8 項目に対して、2 つの潜在因子 AT および BE が対応する測定モデルの構造図である。本モデルでは、LUAT1～LUAT3 の 3 項目が AT 因子に、LUBE1～LUBE5 の 5 項目が BE 因子にそれぞれ対応付けられている。各矢印上の数値は Std.all を表しており、BE 因子においては LUBE1 (0.90) や LUBE2 (0.91)、LUBE3 (0.76) が高い負荷量を示しており、BE をよく表現していることがわかる。一方、LUBE4 は 0.45 とやや低く、BE との関連が弱いことが示唆される。LUBE5 も比較的低めの 0.57 となっているが、許容範囲内と考えられる。

AT 因子に関しては、LUAT1～LUAT3 の 3 項目すべてが 0.80 以上の高い因子負荷量を示しており、AT が一貫した構成概念として測定されていることが確認できる。

また、AT と BE の間には 0.57 程の相関があり、両因子が中程度の正の関連を持つことが視覚的にも示されている。

2.3 モデルの比較

以上の結果から、一因子と二因子のモデルを比較する。まず、表 4 (1 因子モデル) および表 7 (2 因子モデル) に示した通り、以下の点で 2 因子モデルの方が適合度が大幅に改善していることが分かる (まとめたものを表 10 として改めて掲載)。

表 10 適合度指標の比較

指標	1 因子モデル	2 因子モデル	判断基準	コメント
GFI	0.734	0.931	≥ 0.90	2 因子モデルで改善
AGFI	0.521	0.869	≥ 0.85	同上
RMSEA	0.243	0.114	≤ 0.10	両モデルとも高めだが改善
SRMR	0.130	0.066	≤ 0.08	明確に改善

また、因子負荷量に関して、1 因子モデルでは、LUBE4 (0.451) や LUAT 項目の因子負荷量がやや低めで、因子構造にばらつきが見られた。一方、2 因子モデルでは、LUAT1~3 が AT 因子に高い因子負荷量 (0.80 以上) を示し、LUBE1~3 も BE に対して強く結びついていた。ただし、LUBE4 は 2 因子モデルでも因子負荷量が 0.451 とやや低く、改善の余地がある。

表 11 信頼性および妥当性指標の比較

因子	モデル	α 係数	CR	AVE	コメント
LU	1 因子	0.869	0.859	0.447	AVE が基準未満で収束的妥当性にやや懸念
AT	2 因子	0.864	0.865	0.682	全指標が良好
BE	2 因子	0.849	0.850	0.546	全指標が許容範囲内

表 11 より、2 因子モデルでは CR・AVE が共に改善され、特に AT 因子の AVE は 0.68 と非常に高く、測定精度の向上が見られる。

以上の結果から、1 因子モデルに比べて 2 因子モデルの方が、モデルの適合度指標、因子負荷構造、信頼性および収束的妥当性の全ての面で優れていると評価できる。すなわち、LUAT 系列と LUBE 系列をそれぞれ別の因子 (AT と BE) として構造化することにより、より妥当かつ解釈可能性の高い測定モデルが構築可能であることが示された。

3 LUBE4 を除外した 2 因子の確認的因子分析

3.1 LUBE4 除外の 2 因子 CFA の実行

前節と同様の流れでモデルの構築、推定、適合度指標の確認、結果の可視化、信頼性・妥当性の検討を行い、元の 2 因子 CFA との比較および解釈を行う。実行したコードは以下。

ソースコード 11 BE4 除外 2 因子 CFA の実行

```

1 model_cfa_2F_trim <- '
2   ~~AT=~LUAT1+LUAT2+LUAT3
3   ~~BE=~LUBE1+LUBE2+LUBE3+LUBE5
4   '
5 result_cfa_2F_trim <- lavaan::sem(model_cfa_2F_trim, data = dat_lu)
6 fitMeasures(result_cfa_2F_trim)
7 summary(result_cfa_2F_trim, standardized = TRUE)
8 fit_2F_trim <- cfa(model_cfa_2F_trim, data = dat_lu)

```

```

9 lavaanPlot(model = fit_2F_trim,
10             edge_options = list(color = "grey20"),
11             coefs = T, covs = T, stand = TRUE)
12
13 alpha.coef(dat_lu[, 1:3])
14 alpha.coef(dat_lu[, c("LUBE1", "LUBE2", "LUBE3", "LUBE5")])
15 standardizedSolution(result_cfa_2F_trim)
16 std_est_2F_trim <- standardizedSolution(result_cfa_2F_trim)
17 cr_ave("AT", std_est_2F_trim)
18 cr_ave("BE", std_est_2F_trim)

```

表 12 モデル適合度指標 (除 LUBE4)

指標	値	判断基準
GFI	0.965	≥ 0.90
AGFI	0.924	≥ 0.85
RMSEA	0.086	≤ 0.1
SRMR	0.06	≤ 0.08

表 12 に示すモデルの適合度指標は、 $GFI = 0.965 (\geq 0.90)$ 、 $AGFI = 0.924 (\geq 0.85)$ 、 $RMSEA = 0.086 (\leq 0.1)$ 、 $SRMR = 0.06 (\leq 0.08)$ といずれも基準を満たしており、モデル全体の適合度は非常に良好であると判断できる。

表 13 AT と BE に対する各指標の因子負荷量と有意性 (除 LUBE4 モデル)

因子	項目	Std.all	z 値	P 値
AT	LUAT1	0.802	—	—
AT	LUAT2	0.846	15.656	$< .001$
AT	LUAT3	0.829	15.419	$< .001$
BE	LUBE1	0.899	—	—
BE	LUBE2	0.918	22.630	$< .001$
BE	LUBE3	0.743	16.335	$< .001$
BE	LUBE5	0.558	10.874	$< .001$

表 13 に示すように、因子 AT は LUAT1～LUAT3 の 3 項目すべてに対して高い因子負荷量 (0.80～0.85 程度) を示しており、十分な関連性が確認された。BE 因子に関しても LUBE1～LUBE3 は高い因子負荷量を示しているが、LUBE5 に関しては 0.558 とやや低く、これまでのモデルと同様に妥当性の面で慎重な評価が必要である。ただし、他の変数に関しては最も低いもので LUBE3(0.743) と良好な数値を維持しており、十分に 2 因子と関連を示している。

表 14 AT と BE の信頼性および妥当性指標 (除 LUBE4)

因子	指標	値	判断基準
AT	クロンバック α	0.864	≥ 0.70
AT	CR	0.865	≥ 0.70
AT	AVE	0.682	≥ 0.50
BE	クロンバック α	0.858	≥ 0.70
BE	CR	0.867	≥ 0.70
BE	AVE	0.628	≥ 0.50

表 14 に示すように、潜在因子 AT および BE のいずれにおいても、クロンバック α 係数および CR はそれぞれ 0.86 前後と高く、いずれも基準値 (≥ 0.70) を十分に満たしている。これにより、各因子に含まれる観測変数群が高い一貫性を持ち、安定的に同一の概念を測定していることが示された。また、収束的妥当性を示す AVE は、AT が 0.682、BE が 0.628 といずれも非常に高い値を示しており、観測変数が潜在因子を強く反映していることを意味する。以上の結果から、今回のモデルにおいても、AT および BE はともに信頼性・妥当性の両面において十分な水準を満たしていると評価できる。




図 9 LUBE4 を除いた CFA モデルの構造図

図 9 は、LUAT1～LUAT3 の 3 項目が AT 因子に、LUBE1～LUBE5 の 5 項目が BE 因子にそれぞれ対応付けられている構造を示している。図 8 とほぼ同様に、BE 因子においては LUBE1 (0.90) や LUBE2 (0.92)、LUBE3 (0.74) が高い負荷量を示しており、BE をよく表現していることがわかる。一方、LUBE5 は 0.56 とやや低い。AT 因子に関しては、LUAT1～LUAT3 の 3 項目すべてが 0.80 以上の高い因子負荷量を示しており、AT が一貫した構成概念として測定されていることが確認できる。

また、AT と BE の間には 0.57 程の相関があり、元の 2 因子モデルと同様である。

3.2 二つの二因子モデルの比較

以上の結果から、LUBE4 の有無による二つの二因子モデルを比較する。まず、表 7 および表 12 に示した通り、以下の点で後者の 2 因子モデルの方が適合度が改善していることが分かる (まとめたものを表 15 として改めて掲載)。

表 15 適合度指標の比較

指標	元のモデル	除 LUBE モデル	判断基準	コメント
GFI	0.931	0.965	≥ 0.90	LUBE4 除去で改善
AGFI	0.869	0.924	≥ 0.85	同上
RMSEA	0.114	0.086	≤ 0.10	明確に改善し基準クリア
SRMR	0.066	0.06	≤ 0.08	やや改善

また、因子負荷量に関して、元のモデルでは、LUBE4 (0.451) が最も低く、因子構造にばらつきを与えていたが、こちらを除去したことで、LUBE5(0.558) が最低で、他は全て 0.74 以上と、高い数値を維持する結果となった。

表 16 信頼性および妥当性指標の比較

因子	モデル	α 係数	CR	AVE	コメント
AT	除去前	0.864	0.865	0.682	全指標が良好
BE	除去前	0.849	0.850	0.546	全指標が許容範囲内
AT	除去後	0.864	0.865	0.682	全指標が良好
BE	除去後	0.858	0.867	0.628	全指標が良好

表 16 の通り、LUBE4 を除外したモデルでは、BE 因子の AVE が大きく改善され、測定精度の向上が確認された。その結果、適合度指標、因子負荷構造、信頼性指標、および収束的妥当性のすべてにおいて基準を満たす数値が得られた。以上より、AT および BE という二因子によって、LUBE4 を除いた 7 つの観測変数を妥当に説明する CFA モデルが構築できたと評価できる。